

# 概要目录

## 1 随机过程初步

- 基本术语、随机变量和分布函数性质的复习
- 随机过程的两个简单例子
- 一般随机过程的分类




# 基本术语、随机变量和分布函数性质的复习

- 概率空间 $(\Omega, F, P)$ 的三个要素:  $\Omega$ ,  $F$ ,  $P$
- 样本空间 $\Omega$ : 实验或随机试验所有可能结果的集合, 而随机试验中的每个可能结果称为样本点。如: 掷硬币、投骰子、抽扑克牌
- 事件 $\Sigma$ : 样本空间的一个子集
- 样本空间 $\Omega$ 的幂集 $F$ : 集合元素为事件 $\Sigma$
- 概率 $P$ : 从集合 $F$ 到实数域 $R$ 的函数,  $P: F \rightarrow R$ 。每个事件都被赋予一个0和1之间的概率值, 且 $P(\Omega) = 1$ 。简写 $Pr\{\cdot\}$



# 基本术语、随机变量和分布函数性质的复习

- 实随机变量 $X$ : 从样本空间 $\Omega$ 映射到实数域的函数 $X: \Omega \rightarrow R$



# 基本术语、随机变量和分布函数性质的复习

- 如何理解  $Pr\{\omega \in \Omega : X(\omega) > 0\}$ ?
  - 事件  $\{\omega \in \Omega : X(\omega) > 0\}$ : 使  $X$  为正的样本集合
  - 概率  $Pr\{\cdot\}$ : 事件的概率值
- 例如, 随机掷两个骰子, 整个样本空间可以由36个元素组成:  
 $S = \{(i, j) | i = 1, \dots, 6; j = 1, \dots, 6\}$
- 随机变量  $X$  (获得的两个骰子的点数和) 可以有11个整数值  
 $X(i, j) := i + j, x = 2, 3, \dots, 12$
- 随机变量  $Y$  (获得的两个骰子的点数差) 只有6个整数值  
 $Y(i, j) := |i - j|, y = 0, 1, \dots, 5$



# 基本术语、随机变量和分布函数性质的复习

- 缩写词r.v.表示“实随机变量(real random variables)”
- 离散型的r.v. $X$ : 如果存在有限或可列个不同的值 $\lambda_1, \lambda_2, \dots$ 使得 $a_i \equiv Pr\{X = \lambda_i\} > 0, i = 1, 2, \dots$ , 而且 $\sum_i a_i = 1$
- 连续型的r.v. $X$ : 若对每个实数 $\lambda, Pr\{X = \lambda\} = 0$
- 分布函数 $F$ :  $F(\lambda) = Pr\{X \leq \lambda\}$
- 概率密度 $p$ : 如果存在非负函数 $p(t), -\infty < t < \infty$ , 使得r.v. $X$ 的分布函数 $F(\lambda) = \int_{-\infty}^{\lambda} p(t)dt$



# 基本术语、随机变量和分布函数性质的复习

- 离散型r.v.的 $m$ 阶矩:  $E[X^m] = \sum_i \lambda_i^m Pr\{X = \lambda_i\}$ , 假定级数绝对收敛
- 连续型r.v.的 $m$ 阶矩:  $E[X^m] = \int_{-\infty}^{\infty} x^m p(x) dx$ , 假定积分绝对收敛
- $X$ 的一阶矩通常称为均值或期望, 用 $m_X$ 或 $\mu_X$ 表示
- $X$ 的 $m$ 阶中心矩定义为r.v. $X - m_X$ 的 $m$ 阶矩
- 一阶中心矩为0, 二阶中心距称为 $X$ 的方差, 记为 $\sigma_X^2$
- r.v. $X$ 的中位数 $\nu$ :  $Pr\{X \geq \nu\} \geq \frac{1}{2}, Pr\{X \leq \nu\} \geq \frac{1}{2}$



# 基本术语、随机变量和分布函数性质的复习

- 如果 $X$ 是r.v.,  $g$ 是函数, 那么 $Y = g(X)$ 也是随机变量
- 对离散型的r.v. $X$ :  $E[g(X)] = \sum_{i=1}^{\infty} g(\lambda_i) Pr\{X = \lambda_i\}$
- 对连续型的r.v. $X$ :  $E[g(X)] = \int g(t) p_X(t) dt$



# 联合分布函数

- 联合分布函数:  $F(\lambda_1, \lambda_2) = F_{XY}(\lambda_1, \lambda_2) = \Pr\{X \leq \lambda_1, Y \leq \lambda_2\}$
- 边缘分布函数:  $F(\lambda, +\infty) \equiv \lim_{\lambda_2 \rightarrow \infty} F(\lambda_1 = \lambda, \lambda_2)$   
 $F(+\infty, \lambda) \equiv \lim_{\lambda_1 \rightarrow \infty} F(\lambda_1, \lambda_2 = \lambda)$
- 相互独立:  $F(\lambda_1, \lambda_2) = F(\lambda_1, +\infty) \cdot F(+\infty, \lambda_2)$
- 联合概率密度  $p_{XY}$ : 如果存在二元实变量的非负函数  $p_{XY}(s, t)$  使得  $F_{XY}(\lambda_1, \lambda_2) = \int_{-\infty}^{\lambda_2} \int_{-\infty}^{\lambda_1} p_{XY}(s, t) ds dt$
- 如果  $X, Y$  相互独立, 则有  $p_{XY}(s, t) = p_X(s) \cdot p_Y(t)$ , 其中  $p_X$  和  $p_Y$  分别是  $X$  和  $Y$  的边缘分布概率密度





# 联合分布函数

- 多个r.v.的联合分布函数:  $F(\lambda_1, \lambda_2, \dots, \lambda_n) = F_{X_1, X_2, \dots, X_n}(\lambda_1, \lambda_2, \dots, \lambda_n) = Pr\{X_1 \leq \lambda_1, X_2 \leq \lambda_2, \dots, X_n \leq \lambda_n\}$
- 多个r.v.的边缘分布函数:  
 $F_{X_{i_1}, \dots, X_{i_k}}(\lambda_{i_1}, \dots, \lambda_{i_k}) = \lim_{\lambda_i \rightarrow \infty, i \neq i_1, \dots, i_k} F(\lambda_1, \dots, \lambda_n)$
- 多个r.v.相互独立:  $F(\lambda_1, \dots, \lambda_n) = F_{X_1}(\lambda_1) \cdot \dots \cdot F_{X_n}(\lambda_n)$
- 多个r.v.联合概率密度: 如果存在实变量的非负函数 $p(t_1, \dots, t_n)$ 使得 $F(\lambda_1, \dots, \lambda_n) = \int_{-\infty}^{\lambda_n} \dots \int_{-\infty}^{\lambda_1} p(t_1, \dots, t_n) dt_1 \dots dt_n$



# 联合分布函数

- 如果 $X$ 和 $Y$ 分别具有均值 $m_X$ 和 $m_Y$ ,协方差 $\sigma_{XY}$ 定义为乘积矩:  
$$\sigma_{XY} = E[(X - m_X)(Y - m_Y)]$$
- 当 $X_1$ 和 $X_2$ 相互独立,  $X = X_1 + X_2$ 的概率密度 $p$ 是 $p_1$ 和 $p_2$ 的卷积:  
$$p(x) = \int p_1(x - y)p_2(y)dy = \int p_2(x - y)p_1(y)dy$$



# 条件分布和条件期望

- 已知事件 $B$ 的条件下, 事件 $A$ 的条件概率:

$$Pr\{A|B\} = \frac{Pr\{AB\}}{Pr\{B\}}, Pr\{B\} > 0$$

- 已知 $Y = y$ 时, 离散型 $X$ 的条件分布函数:

$$F_{X|Y}(x|y) = \frac{Pr\{X \leq x, Y=y\}}{Pr\{Y=y\}}, Pr\{Y=y\} > 0$$

- 已知 $Y = y$ 时, 连续型 $X$ 的条件分布函数:

$$F_{X|Y}(x|y) = \frac{\int_{\xi \leq x} p_{XY}(\xi, y) d\xi}{p_Y(y)}, p_Y(y) > 0$$

- 条件分布的三个本质特征:

- 对每个固定的 $y$ ,  $F_{X|Y}(x|y)$ 是 $X = x$ 的分布函数
- 对每个固定的 $x$ ,  $F_{X|Y}(x|y)$ 是 $y$ 的函数
- 对任意 $x, y$ ,  $Pr\{X \leq x, Y \leq y\} = \int_{\eta \leq y} F_{X|Y}(x|\eta) p_Y(\eta) d\eta$   
或  $Pr\{X \leq x, Y \leq y\} = \sum_{\eta \leq y} F_{X|Y}(x|\eta) Pr\{Y = \eta\}$



# 条件分布和条件期望

- 全概率公式:  $Pr\{X \leq x\} = \sum_y Pr\{X \leq x | Y = y\} Pr\{Y = y\}$   
或  $Pr\{X \leq x\} = \int_{-\infty}^{+\infty} Pr\{X \leq x | Y = y\} p_Y(y) dy$

- 已知  $Y = y$  时, 条件密度函数:

$$p_{X|Y}(x|y) = \frac{d}{dx} F_{X|Y}(x|y) = \frac{p_{XY}(x,y)}{p_Y(y)}, p_Y(y) > 0$$

- 已知  $Y = y$  时,  $g(X)$  的条件期望:

$$E[g(X) | Y = y] = \int g(x) p_{X|Y}(x|y) dx = \frac{\int g(x) p_{XY}(x,y) dx}{p_Y(y)}, p_Y(y) > 0$$

$$\text{或} = \sum_{i=1}^{\infty} g(x_i) Pr\{X = x_i | Y = y\} = \frac{\sum_{i=1}^{\infty} g(x_i) Pr\{X = x_i, Y = y\}}{Pr\{Y = y\}},$$
$$Pr\{Y = y\} > 0$$

- 对于每个函数  $g$ , 若  $E[|g(X)|] < +\infty$ , 则  $E[g(X) | Y = y]$  是  $y$  的函数



# 条件分布和条件期望

- 对于任意有界函数 $h$ ,  
 $E[g(X)h(Y)] = \sum_{i=1}^{\infty} E[g(X)|Y = y_i]h(y_i)Pr\{Y = y_i\}$   
或 $E[g(X)h(Y)] = \int E[g(X)|Y = y]h(y)p_Y(y)dy$
- 期望的全概率公式:  $E[g(X)] = \sum_{i=1}^{\infty} E[g(X)|Y = y_i]Pr\{Y = y_i\}$   
或 $E[g(X)] = \int E[g(X)|Y = y]p_Y(y)dy$
- 条件期望的性质:  $E[a_1g_1(X) + a_2g_2(X)|Y = y]$   
 $= a_1E[g_1(X)|Y = y] + a_2E[g_2(X)|Y = y]$
- $E[g(X)|Y = y]$ 是实变量 $y$ 的函数, 记为随机变量 $E[g(X)|Y]$
- 对于任意有界函数 $h$ ,  $E[g(X)h(Y)] = E\{E[g(X)|Y]h(Y)\}$
- 期望的全概率公式:  $E[g(X)] = E\{E[g(X)|Y]\}$



# 条件分布和条件期望

- $E[a_1g(X_1) + a_2g(X_2)|Y] = a_1E[g(X_1)|Y] + a_2E[g(X_2)|Y]$
- 若 $X$ 和 $Y$ 独立, 则 $E[g(X)|Y] = E[g(X)]$
- $E[g(X)f(Y)|Y] = f(Y)E[g(X)|Y]$
- $E[g(X)f(Y)] = E\{E[g(X)|Y]f(Y)\}$
- $E[c|Y] = c$
- $E[f(Y)|Y] = f(Y)$
- $E[g(X)] = E\{E[g(X)|Y]\}$



# 特征函数

- 特征函数  $\phi(t) = E[e^{itX}]$ ,  $i = \sqrt{-1}$ ,  $-\infty < t < +\infty$
- $\phi(t) = \int_{-\infty}^{\infty} e^{it\lambda} p(\lambda) d\lambda$ , 或  $\phi(t) = \sum_{k=0}^{\infty} e^{it\lambda_k} Pr\{X = \lambda_k\}$
- 缩写词c.f.表示“特征函数(characteristic function)”
- 特征函数的重要意义:
  - 分布函数与特征函数之间一一对应, 用特征函数表达分布函数的方程式是勒维(Levy)变换公式
  - 相互独立的随机变量的和的特征函数是它们的特征函数的乘积
  - 由特征函数的微商得到矩:  $E[X^k] = \frac{1}{i^k} \phi^{(k)}(0) = \frac{1}{i^k} \frac{d^k \phi(0)}{dt^k}$



# 母函数和拉普拉斯变换

- 对于仅取非负整数值的随机变量，与特征函数相应的母函数定义：

$$g(s) = \sum_{k=0}^{\infty} s^k \Pr\{X = k\} = E[s^X], \quad s \text{ 是复变量, 且 } |s| \leq 1$$

- 母函数可经过变量替换  $s = e^{it}$  变成  $X$  的特征函数：

$$\phi(t) = E[e^{itX}] = E[(e^{it})^X] = g(e^{it})$$

- 母函数的基本性质：
  - 母函数唯一确定其分布函数
  - 独立非负整数值随机变量和的母函数是它们母函数的乘积
  - 各阶矩可通过逐次微分得到，阶乘矩由下式得到：

$$E[X(X-1)\dots(X-k)] = g^{(k+1)}(1) = \frac{d^{k+1}g(1)}{ds^{k+1}}$$

$$E[X] = g^{(1)}(1), E[X^2] = g^{(2)}(1) + g^{(1)}(1)$$





# 母函数和拉普拉斯变换

- 例子：设 $N, X_1, X_2, \dots$ 是独立非负整数值随机变量， $N$ 的母函数为 $g_N(s)$ ，并假定 $X_i$ 同分布，具有相同的母函数 $g(s)$ ，请确定和 $R = X_1 + X_2 + \dots + X_N$ 的母函数 $g_R(s)$
- $$\begin{aligned} g_R(s) &= E[s^R] = E[s^{X_1 + \dots + X_N}] = E\{E[s^{X_1 + \dots + X_N} | N]\} \\ &= \sum_{n=0}^{\infty} E[s^{X_1 + \dots + X_n} | N = n] Pr\{N = n\} \\ &= \sum_{n=0}^{\infty} E[s^{X_1 + \dots + X_n}] Pr\{N = n\} \\ &= \sum_{n=0}^{\infty} g^n(s) Pr\{N = n\} \\ &= E[g^N(s)] = g_N[g(s)] \end{aligned}$$
- 利用复合函数微分链式法则，有 $g'_R(s) = g'_N[g(s)] \cdot g'(s)$   
令 $s = 1$ , 得 $E[R] = E[N] \cdot E[X]$
- 再计算二阶微分 $g''_R(s) = g''_N[g(s)] \cdot (g'(s))^2 + g'_N[g(s)] \cdot g''(s)$   
得到 $g''_R(1) = g''_N(1) \cdot E[X]^2 + E[N] \cdot g''(1)$



# 母函数和拉普拉斯变换

- 回顾  $g''(1) = E[X(X-1)] = E[X^2] - E[X] = \sigma_X^2 + E[X]^2 - E[X]$
- 类似地,  $g_R''(1) = \sigma_R^2 + E[R]^2 - E[R]$ ,  $g_N''(1) = \sigma_N^2 + E[N]^2 - E[N]$
- 代入  $g_R''(1) = g_N''(1) \cdot E[X]^2 + E[N] \cdot g''(1)$ , 得到
- $$\begin{aligned} & \sigma_R^2 + E[R]^2 - E[R] \\ &= (\sigma_N^2 + E[N]^2 - E[N]) \cdot E[X]^2 + E[N] \cdot (\sigma_X^2 + E[X]^2 - E[X]) \\ &= (\sigma_N^2 + E[N]^2) \cdot E[X]^2 + E[N] \cdot (\sigma_X^2 - E[X]) \\ &= \sigma_N^2 \cdot E[X]^2 + (E[N] \cdot E[X])^2 + E[N] \cdot \sigma_X^2 - E[N] \cdot E[X] \end{aligned}$$
- 利用上面结论  $E[R] = E[N] \cdot E[X]$ , 得到

$$\sigma_R^2 = E[X]^2 \sigma_N^2 + E[N] \sigma_X^2$$

- 推广到特征函数  $\phi_R(t) = g_N(\phi(t))$



# 母函数和拉普拉斯变换

- 非负随机变量的拉普拉斯变换:  $\psi_X(s) = E[e^{-sX}]$ ,  $s$ 是复变量
- $\psi_X(s) = \int_0^{\infty} e^{-sx} p_X(x) dx$ , 或  $\psi_X(s) = \sum_{n=0}^{\infty} e^{-s\lambda_n} Pr\{X = \lambda_n\}$
- 拉普拉斯变换与特征函数的关系:  $s = it$ 时,  $\psi_X(s) = \phi_X(-t)$
- 对相互独立的非负随机变量组,  $\psi_{X_1+\dots+X_n}(s) = \prod_{k=1}^n \psi_{X_k}(s)$
- 拉普拉斯变换唯一确定其分布函数



# 分布函数的例子

## 常见的连续型概率分布

连续型分布	密度函数 $p(x)$	参数范围	特征函数 $\phi(t)$	均值	方差
正态分布	$\frac{1}{\sqrt{2\pi}\sigma} \exp -\frac{(x-m)^2}{2\sigma^2}$ $-\infty < x < \infty$	$m$ 实数 $\sigma > 0$	$\exp \left[ -\frac{\sigma^2 t^2}{2} + imt \right]$	$m$	$\sigma^2$
指数分布	$\lambda e^{-\lambda x}, x > 0$	$\lambda > 0$	$\frac{\lambda}{\lambda - it}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
$\Gamma$ 分布	$\frac{\lambda}{\Gamma(\alpha)} (\lambda x)^{\alpha-1} e^{-\lambda x},$ $x > 0$	$\lambda > 0$ $\alpha > 0$	$\frac{\lambda^\alpha}{(\lambda - it)^\alpha}$	$\frac{\alpha}{\lambda}$	$\frac{\alpha}{\lambda^2}$
均匀分布	$\frac{1}{b-a}, a < x < b$	$a < b$	$\frac{e^{iub} - e^{iua}}{iu(b-a)}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Beta 分布	$\frac{\Gamma(p+q)}{\Gamma(p)\Gamma(q)} x^{p-1} (1-x)^{q-1},$ $0 < x < 1$	$p > 0$ $q > 0$	$\frac{\Gamma(p+q)}{\Gamma(p)\Gamma(q)} \int_0^1 e^{itx} x^{p-1} (1-x)^{q-1} dx$	$\frac{p}{p+q}$	$\frac{qp}{(p+q)^2(p+q+1)}$



# 分布函数的例子

## 常见的离散型概率分布

离散型分布	概率分布列	参数的可能取值	母函数	均值	方差
泊松分布	$\frac{e^{-\lambda} \lambda^n}{n!}, n = 0, 1, 2, \dots$	$\lambda > 0$	$e^{-\lambda + \lambda s}$	$\lambda$	$\lambda$
二项分布	$\binom{N}{n} p^n q^{N-n}, n = 0, 1, \dots, N$	$N = 1, 2, \dots$ $0 < p < 1$ $q = 1 - p$	$(1 - p + ps)^N$	$Np$	$Npq$
负二项 (巴斯卡) 分布	$\binom{\alpha + n - 1}{n} p^\alpha q^n, n = 0, 1, 2, \dots$	$\alpha > 0$ $0 < p < 1$	$\left(\frac{p}{1 - qs}\right)^\alpha$	$\frac{\alpha q}{p}$	$\frac{\alpha q}{p^2}$
几何分布	$p(1 - p)^n, n = 0, 1, 2, \dots$	$0 < p < 1$	$\frac{p}{1 - qs}$	$\frac{q}{p}$	$\frac{q}{p^2}$





# 多元正态分布

- 联合正态分布:  $Pr\{X_1 \leq a, X_2 \leq b\}$

$$= \int_{-\infty}^a \int_{-\infty}^b \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2}Q(x_1, x_2)\right\} dx_1 dx_2,$$

$$\text{其中 } Q(x_1, x_2) = \frac{1}{1-\rho^2} \left\{ \left( \frac{x_1 - m_1}{\sigma_1} \right)^2 - 2\rho \left( \frac{x_1 - m_1}{\sigma_1} \right) \left( \frac{x_2 - m_2}{\sigma_2} \right) + \left( \frac{x_2 - m_2}{\sigma_2} \right)^2 \right\}$$



# 多元正态分布

- 容易验证  $E[X_i] = m_i$ ,  
 $X_i$  的方差是  $\sigma_i^2$
- 协方差为  $E[(X_1 - m_1)(X_2 - m_2)] = \rho\sigma_1\sigma_2$ ,  
 $\rho$  称为相关系数
- 联合特征函数:  $\phi_{X_1, X_2}(t_1, t_2) = E[e^{i(t_1 X_1 + t_2 X_2)}]$   
 $= \exp\{i(t_1 m_1 + t_2 m_2) - \frac{1}{2}(t_1^2 \sigma_1^2 + 2\rho t_1 \sigma_1 t_2 \sigma_2 + t_2^2 \sigma_2^2)\}$
- 已知  $X_1 = x_1$  时  $X_2$  的条件概率密度函数  
 $p_{X_2|X_1}(x_2|x_1) = \frac{1}{\sqrt{2\pi}\sigma} \exp[-\frac{1}{2}(\frac{x_2 - m}{\sigma})^2]$ ,  
其中  $m = m_2 + \frac{\sigma_2}{\sigma_1}\rho(x_1 - m_1)$ ,  $\sigma = \sigma_2\sqrt{1 - \rho^2}$



# 多项分布

- 多项分布：取非负整数值 $0, \dots, n$ 的 $r$ 个离散型随机变量的联合分布
$$Pr\{X_1 = k_1 \dots X_r = k_r\} = \begin{cases} \frac{n!}{k_1! \dots k_r!} p_1^{k_1} \dots p_r^{k_r}, & \text{if } k_1 + \dots + k_r = n \\ 0, & \text{otherwise} \end{cases}$$
其中 $p_i > 0, i = 1, \dots, r$ , 且 $\sum_{i=1}^r p_i = 1$
- 举例：将 $n$ 个球顺序取出随机放到 $r$ 个不同的篮子里，放到第 $i$ 个篮子的概率为 $p_i$
- 第 $i$ 个篮子恰好有 $k_i$ 个球的组合数为 $\frac{n!}{k_1! \dots k_r!}$
- 因此，第 $i$ 个篮子恰好有 $k_i$ 个球的概率为 $\frac{n!}{k_1! \dots k_r!} p_1^{k_1} \dots p_r^{k_r}$
- 多项分布的联合母函数
$$g(s_1, \dots, s_r) = E[s_1^{X_1} \dots s_r^{X_r}] = (p_1 s_1 + \dots + p_r s_r)^n$$





# 多项分布

## ● 组合数学相关知识回顾:

	排列 $\{a, b\} \neq \{b, a\}$ (考虑顺序)	组合 $\{a, b\} = \{b, a\}$ (不考虑顺序)
不重复出现 (不放回去) $\{a, b, c\}$	$P_n^k$	$C_n^k$
重复出现 (再放回去) $\{a, a, b\}$	$n^k$	$H_n^k$

$$P_n^k = \frac{n!}{(n-k)!}$$

$$C_n^k = \binom{n}{k} = \frac{P_n^k}{k!} = \frac{n!}{k!(n-k)!}$$

$$H_n^k = C_{n+k-1}^k = \binom{n+k-1}{k}$$

## ● 为什么 $H_n^k = C_{n+k-1}^k$ ?

● 提示: 建立  $H_n^k$  计数与  $C_{n+k-1}^k$  计数的一一对应



# 极限定理

- 以概率1收敛: 若  $Pr\{\lim_{n \rightarrow \infty} Z_n = Z\} = 1$ , 则说  $Z_n$  以概率1收敛于  $Z$ ,
  - 以概率1出现结果:  $Z = z, Z_1 = z_1, \dots$ , 且  $\lim_{n \rightarrow \infty} z_n = z$
- 依概率收敛: 若对每个正数  $\varepsilon$ ,  $\lim_{n \rightarrow \infty} Pr\{|Z_n - Z| > \varepsilon\} = 0$  或者  $\lim_{n \rightarrow \infty} Pr\{|Z_n - Z| \leq \varepsilon\} = 1$  成立, 则说  $Z_n$  依概率收敛于  $Z$ ,
  - 可以取到足够大的  $n$ , 使得  $Z_n$  任意接近  $Z$  的概率任意接近1.
- 利用样本函数解释概念(①, ②,  $\dots$ , ③)表示随机变量序列的一个实现)

	$a_1, a_2, a_3, \dots, a_n, \dots \rightarrow a$
	$Z_1, Z_2, Z_3, \dots, Z_n, \dots \rightarrow Z$
①	$z_1^1, z_2^1, z_3^1, \dots, z_n^1, \dots \rightarrow z^1$
②	$z_1^2, z_2^2, z_3^2, \dots, z_n^2, \dots \rightarrow z^2$
$\dots$	$\dots, \dots, \dots, \dots, \dots, \dots \rightarrow \dots$
③	$z_1^m, z_2^m, z_3^m, \dots, z_n^m, \dots \rightarrow z^m$



# 极限定理

- 二次平均收敛(均方收敛): 若  $\lim_{n \rightarrow \infty} E[|Z_n - Z|^2] = 0$ , 则说  $Z_n$  二次平均收敛(均方收敛)于  $Z$ ,
  - 可以取到足够大的  $n$ , 在差的平方平均意义下  $Z_n$  任意逼近  $Z$ .
- 依分布收敛: 设  $F(t) = Pr\{Z \leq t\}$  和  $F_k(t) = Pr\{Z_k \leq t\}$ ,  $k = 1, 2, \dots$ , 如果  $\lim_{n \rightarrow \infty} F_n(t) = F(t)$  对所有  $F$  的连续点  $t$  成立, 则说  $Z_n$  依分布收敛于  $Z$ .
- $Z_n$  以概率1收敛于  $Z \Rightarrow Z_n$  依概率收敛于  $Z \Rightarrow Z_n$  依分布收敛于  $Z$ .
  - 举例: 满足依概率收敛, 但不满足以概率1收敛(超出课程要求)?
  - 考虑序列  $Z_{1,1}, Z_{1,2}, Z_{2,2}, Z_{1,3}, Z_{2,3}, Z_{3,3}, \dots$

$$Z_{i,j} = \begin{cases} 1 & \omega \in [\frac{i-1}{j}, \frac{i}{j}) \\ 0 & \text{其它} \end{cases},$$

随机变量  $\Omega = \omega$  在  $(0, 1)$  内服从均匀分布



# 极限定理

- 设 $X_1, X_2, \dots$ 是独立同分布随机变量序列, 具有有限均值 $m$ , 令 $S_n = X_1 + \dots + X_n$ ,  $\bar{X}_n = \frac{S_n}{n}$ 是样本均值.

- 弱大数定理:  $\bar{X}_n$ 依概率收敛于 $m$ , 即, 对任意 $\varepsilon > 0$ , 有

$$\lim_{n \rightarrow \infty} Pr\{|\bar{X}_n - m| > \varepsilon\} = 0.$$

- 强大数定理:  $\bar{X}_n$ 以概率1收敛于 $m$ , 即,

$$Pr\{\lim_{n \rightarrow \infty} \bar{X}_n = m\} = 1.$$

- 中心极限定理: 假设 $X_k$ 有方差 $\sigma^2$ , 设 $Z_n = \frac{S_n - nm}{\sigma\sqrt{n}} = \frac{1}{\sigma}(\bar{X}_n - m)\sqrt{n}$ , 则 $Z_n$ 依分布收敛于一个零均值、单位方差的正态随机变量,

$$\lim_{n \rightarrow \infty} Pr\{Z_n \leq \alpha\} = \int_{-\infty}^{\alpha} \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du, \forall \alpha.$$



# 不等式

- 切比雪夫不等式：设 $Z$ 是非负随机变量，则对任何正数 $c$ ,

$$Pr\{Z > c\} \leq \frac{1}{c}E[Z].$$

$$E[Z] = \int_0^{\infty} zp_Z(z)dz \geq \int_c^{\infty} zp_Z(z)dz \geq c \cdot \int_c^{\infty} p_Z(z)dz = c \cdot Pr\{Z > c\}.$$

- 如果 $X$ 是具有均值 $\mu$ 和方差 $\sigma^2$ 的随机变量，应用切比雪夫不等式于 $Z = (X - \mu)^2$ ，得到

$$Pr\{|X - \mu| > \varepsilon\} = Pr\{Z > \varepsilon^2\} \leq \frac{\sigma^2}{\varepsilon^2}.$$

- 施瓦兹不等式：设 $X, Y$ 是具有有限二阶矩的随机变量，则

$$(E[XY])^2 \leq E[X^2]E[Y^2].$$

- 对实数 $\lambda$ ， $0 \leq E[(X + \lambda Y)^2] = E[X^2] + 2\lambda E[XY] + \lambda^2 E[Y^2]$ 看作 $\lambda$ 的二次函数，它至多有一个实数根，判别式非正

$$4(E[XY])^2 < 4E[X^2]E[Y^2].$$



# 概要目录

## 1 随机过程初步

- 基本术语、随机变量和分布函数性质的复习
- 随机过程的两个简单例子
- 一般随机过程的分类




# 随机过程的两个简单例子

- 随机过程理论主要研究随机变量族 $\{X_t, t \in T\}$ 的构造,
  - $T$ 称为指标集,
  - $X_t$ 或记为 $X(t)$ .
- 随机过程 $\{X_t, t \in T\}$ 的一个实现或样本函数, 是指对每个 $t \in T$ ,  $X_t$ 的可能值的一个指定.
- 指标集可以是离散时间 $T = \{0, 1, 2, \dots\}$ , 这时 $\{X_t\}$ 可以表示一系列试验的结果:
  - 抛掷硬币的一系列结果;
  - 智力测验时对象的一系列反应;
  - 对人口某种特征的一系列观察.



# 随机过程的两个简单例子

- 例如，抛掷骰子的结果5, 1, 3, 2, 2, 4, 1, 6, 3, 6, ...

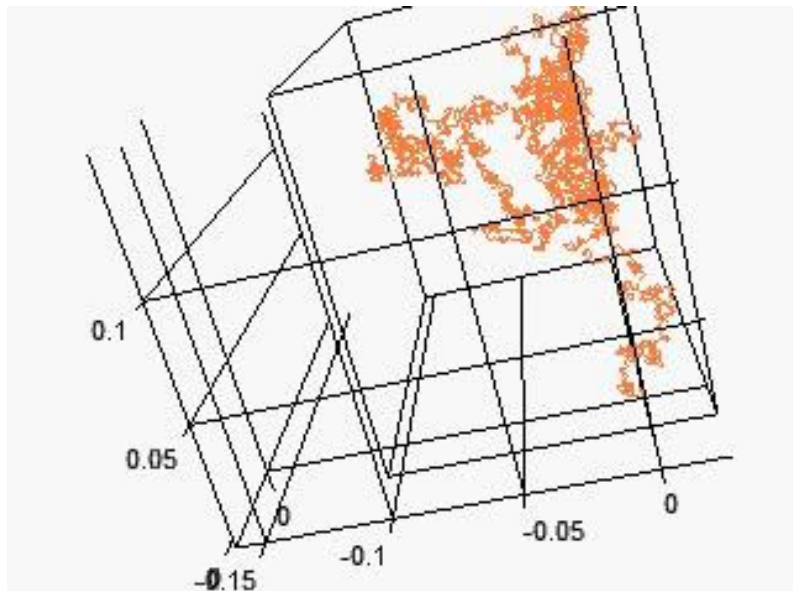


- 指标集  $T = [0, \infty)$  的随机过程在应用中尤为重要,
  - 此时  $t$  通常解释为时间.





# 例1:布朗运动



# 例1:布朗运动

布朗运动(Wiener过程)的特征:

- 独立增量过程: 若对任意 $n$ 个实值 $t_1, t_2, \dots, t_n, t_1 < t_2 < \dots < t_n$ , 随机变量组 $X_{t_2} - X_{t_1}, X_{t_3} - X_{t_2}, \dots, X_{t_n} - X_{t_{n-1}}$ 是独立的.
- 平稳增量过程: 如果增量 $X_t - X_s$ 的分布仅仅依赖于区间长度 $t - s$ 而与 $s$ 无关.
- 增量 $X_t - X_s, t > s$ 的分布函数: 期望为0, 方差为 $B(t - s)$ 的正态分布 (将增量拆分为很小时间段上增量的和, 由中心极限定理猜测增量满足正态分布)

$$Pr\{X_t - X_s \leq x\} = \frac{1}{\sqrt{2\pi B(t-s)}} \int_{-\infty}^x e^{-\frac{u^2}{2B(t-s)}} du,$$

其中 $t > s, B$ 是正常数.



# 例1:布朗运动

- 马尔可夫过程: 对任意  $t_1 < t_2 < \cdots < t_n < t$ ,


$$\begin{aligned} Pr\{a < X_t \leq b | X_{t_1} = x_1, X_{t_2} = x_2, \cdots, X_{t_n} = x_n\} \\ = Pr\{a < X_t \leq b | X_{t_n} = x_n\}. \end{aligned}$$

- 布朗运动是一个马尔可夫过程:
  - 假设  $X_0 = 0$ , 则有  $E[X_t] = 0, \sigma^2(X_t) = Bt$ ,

$$\begin{aligned} Pr\{X_t \leq x | X_{t_1} = x_1, \dots, X_{t_n} = x_n\} \\ = \frac{1}{\sqrt{2\pi B(t - t_n)}} \int_{-\infty}^{x - x_n} e^{-\frac{u^2}{2B(t - t_n)}} du. \end{aligned}$$



## 例2:泊松过程



## 例2:泊松过程

- 泊松过程的特征:

- 平稳独立增量过程.
- 在长度为 $h$ 的时间区间中, 事件至少发生一次的概率为

$$p(h) = ah + o(h), h \rightarrow 0, a > 0.$$

- 在长度为 $h$ 的时间区间中, 事件发生两次或两次以上的概率为 $o(h)$  (稀有事件率、伯努利试验的二项分布导出)

- $X_t$ 的分布函数: 参数为 $at$ 的泊松分布,

$$Pr\{X_t = m\} = \frac{a^m t^m}{m!} e^{-at},$$

其中 $a$ 是正常数.

- 函数 $P_m(t) = Pr\{X_t = m\}$ 是另一个理解随机过程的视角.

- $E[X_t] = at, \sigma^2(X_t) = at.$



# 概要目录

## 1 随机过程初步

- 基本术语、随机变量和分布函数性质的复习
- 随机过程的两个简单例子
- 一般随机过程的分类



# 一般随机过程的分类

- 随机过程的分类要素:状态空间的种类,指标集  $T$  以及随机变量  $X_t$  之间的相关关系.
- 状态空间  $S$ :每个  $X_t$  所有可能值所在的空间.
  - 取自然数值的过程或离散状态空间过程:  $S = \{0, 1, 2, \dots\}$ .
  - 实值随机过程:  $S$  为实直线  $(-\infty, +\infty)$ .
  - $k$  维向量过程:  $S$  是  $k$  维欧几里得空间.
- 指标集  $T$ :
  - 离散时间随机过程:  $T = \{0, 1, 2, \dots\}$ , 常用  $X_n$  代替  $X_t$ .
  - 连续时间过程:  $T = [0, \infty)$ .
  - $T$  可以不是一维的:空间泊松过程,海洋波浪等.
- 随机过程的主要特征:随机变量  $X_t (t \in T)$  之间的相互关系, 由该过程所有有限个随机变量的联合分布函数所确定.



# 随机过程的经典类型：平稳独立增量过程

- 增量:  $X_t - X_s, t > s$ .
- 独立增量过程: 若对任意  $n$  个实值  $t_1, t_2, \dots, t_n, t_1 < t_2 < \dots < t_n$ , 随机变量组  $X_{t_2} - X_{t_1}, X_{t_3} - X_{t_2}, \dots, X_{t_n} - X_{t_{n-1}}$  是独立的.
- 平稳增量过程: 如果增量  $X_t - X_s$  的分布仅仅依赖于区间长度  $t - s$ , 而与  $s$  无关.
- 平稳独立增量过程的均值和方差:
  - $E[X_t] = m_0 + m_1 t$ , 其中  $m_0 = E[X_0], m_1 = E[X_1] - m_0$ .
  - $\sigma_{X_t}^2 = \sigma_0^2 + \sigma_1^2 t$ , 其中  $\sigma_0^2 = E[(X_0 - m_0)^2], \sigma_1^2 = E[(X_1 - m_0 - m_1)^2] - \sigma_0^2$ .
- 布朗运动和泊松过程都满足上述这个性质  
(注意应用中的某个随机过程可能同时满足多个经典类型, 可以选择使用/共同使用不同工具来分析求解)





# 随机过程的经典类型：鞅(martingale)

- 鞅:对任意  $t_1 < t_2 < \cdots < t_{n+1}$ , 以及任意实数  $a_1, a_2, \cdots, a_n$ ,

$$E[X_{t_{n+1}} | X_{t_1} = a_1, X_{t_2} = a_2, \cdots, X_{t_n} = a_n] = a_n.$$

- 可描述公平赌博的模型(是否存在必胜策略? Martingale? )
- 当  $Z_i, i = 1, 2, \cdots$  是相互独立且均值为0的随机变量时,

$$X_n = \sum_{i=1}^n Z_i, n = 1, 2, \cdots$$

是一个离散时间鞅.

- 若  $X_t, 0 \leq t < \infty$ , 具有独立增量且均值为0, 则  $X_t$  是连续时间鞅.



# 随机过程的经典类型：马尔可夫过程

- 马尔可夫过程:对任意  $t_1 < t_2 < \cdots < t_n < t$ ,

$$\begin{aligned}Pr\{a < X_t \leq b | X_{t_1} = x_1, X_{t_2} = x_2, \cdots, X_{t_n} = x_n\} \\ = Pr\{a < X_t \leq b | X_{t_n} = x_n\}.\end{aligned}$$

- 马尔可夫性质蕴涵一个条件独立性, 即“未来 $\perp$ 过去|现在”.  
(思考独立性与条件独立性的区别)

- 转移概率函数:

$$P(x, s; t, A) = Pr\{X_t \in A | X_s = x\}, t > s,$$

$A$ 是实直线上一个区间.

- 马尔可夫链: 状态空间是有限或可数的马尔可夫过程, 如泊松过程
- 扩散过程: 所有样本函数是连续函数的马尔可夫过程, 如布朗运动



# 随机过程的经典类型：平稳过程

- 严格平稳：对任意  $h > 0$  和任意  $t_1, t_2, \dots, t_n \in T$ ，随机变量组  $(X_{t_1+h}, X_{t_2+h}, \dots, X_{t_n+h})$  和  $(X_{t_1}, X_{t_2}, \dots, X_{t_n})$  的联合分布函数相同。
- 特别地，对任意时刻  $t$ ， $X_t$  的分布都相同。
- 称马尔可夫过程有平稳转移概率：如果  $P(x, s; t, A)$  仅是  $t - s$  的函数
- 泊松过程和布朗运动都不是平稳的，但增量  $Z_t = X_{t+h} - X_t$  对任意固定  $h$  是平稳随机过程。
- 不存在非常数的平稳独立增量过程是平稳过程。



# 随机过程的经典类型：更新过程


- 更新过程：独立同分布正随机变量序列 $\{T_k\}_{k=1,2,\dots}$ ， $T_k$ 表示某“元件”的寿命。

- 第 $n$ 次更新时间是

$$S_n = \sum_{i=1}^n T_i.$$

- 更新计数过程 $\{N_t\}$ 表示在时间区间 $[0, t]$ 更新的数目：

$$N_t = n, \text{ 当 } S_n \leq t < S_{n+1}, n = 0, 1, 2, \dots$$



- 带有参数 $\lambda$ 的泊松过程是更新计数过程，其元件寿命具有参数为 $\lambda$ 的指数分布(具有“无记忆性”).



# 随机过程的经典类型：点过程

- 点过程：指标集为集合  $A \in \mathcal{A}$  并以非负整数集  $\{0, 1, \dots, \infty\}$  为状态空间的随机过程，其中  $S$  是  $n$  维空间的一个集合,  $\mathcal{A}$  是  $S$  的一个子集族
- 解释：“点”以某种随机方式散布在  $S$  上,  $N(A)$  表示落在子集  $A$  里的点数
- $N(A_1 \cup A_2) = N(A_1) + N(A_2)$ , 若  $A_1$  和  $A_2$  不相交,  $A_1 \cup A_2 \in \mathcal{A}$ .
- $N(\emptyset) = 0$ , 若  $\emptyset \in \mathcal{A}$ .
- 每个泊松过程  $\{X_t, t \in [0, \infty)\}$  确定  $S = [0, \infty)$  上一个泊松点过程,

$$N((s, t]) = X_t - X_s.$$

